

# Teoria analizy dużych zbiorów - Lista VI

Ryzyko estymacyjne

*MM*

*14 czerwiec 2017*

## Spis treści

<b>1</b>	<b>Wstęp</b>	<b>2</b>
1.1	Założenia i definicje . . . . .	2
1.2	Estymatory . . . . .	2
<b>2</b>	<b>Zadanie 1</b>	<b>3</b>
<b>3</b>	<b>Zadanie 2</b>	<b>4</b>

# 1 Wstęp

W niniejszym raporcie umieszczone zostały rozwiązania szstej listy zadań z przedmiotu **Teoria analizy dużych zbiorów** prowadzonego przez Panią Profesor Małgorzatę Bogdan we współpracy z Panem Michałem Kosem. Na tejże liście poruszony został problem estymacji średniej w przypadku wielowymiarowego rozkładu normalnego. Poniżej przedstawimy cztery estymatory używane w kolejnych ćwiczeniach.

## 1.1 Założenia i definicje

Większość poniższych definicji zostało wprowadzonych w raporcie dot. listy piątej, jednakże przypomnimy je tutaj dla porządku.

Zakładamy, że dysponujemy pojedynczą obserwacją  $X$  z  $p$ -wymiarowego rozkładu normalnego  $N(\mu, I)$ , gdzie  $\mu$  to wektor średnich, a  $\Sigma$  to macierz kowariancji.

Do oceny estymatorów użyjemy estymatora błędu średniokwadratowego [MSE] zdefiniowanego następująco

$$\text{MSE} = \frac{1}{p} \sum_{i=1}^p (X_i - \hat{X}_i)^2$$

gdzie  $X_i$  oraz  $\hat{X}_i$  to odpowiednio  $i$ -ta współrzędna i estymator jej średniej.

## 1.2 Estymatory

### 1.2.1 Estymator największej wiarygodności [MLE]

Najprostszy estymator, to estimator największej wiarygodności, który w przypadku wielowymiarowego rozkładu normalnego jest średnią obserwacji  $X$ . Mamy więc

$$\hat{\mu}_{MLE} = X \quad [\text{średnia}].$$

### 1.2.2 Estymator Jamesa-Steina [JS]

Estymator Jamesa-Steina, to estimator który, zgodnie z teorią, powinien wykazywać mniejszy błąd średniokwadratowy niż estymator największej wiarygodności. Zadany jest on wzorem

$$\hat{\mu}_{JS} = \left(1 - \frac{p-2}{\|X\|^2}\right) X.$$

### 1.2.3 Estymator Jamesa-Steina z modyfikacją Mary Ellen Bock (1975) [MEB]

Jest to modyfikacja estymatora JS, która pozwala na estymację, gdy zmienne są od siebie zależne. Zadany jest on poprzez

$$\hat{\mu}_{MEB} = \left(1 - \frac{\hat{p}-2}{X^T \Sigma^{-1} X}\right) X,$$

gdzie  $\hat{p} = \frac{\text{Tr}(\Sigma)}{\lambda_{\max}(\Sigma)}$ , a  $\text{Tr}(\Sigma)$  i  $\lambda_{\max}(\Sigma)$  to odpowiednio ślad i największa wartość własna macierzy  $\Sigma$ .

### 1.2.4 Estymator odcięciowy [HT]

Jest to nietypowy estymator, używany w głównie w mieszaninach rzadkich. Opera się on na zasadzie odcięcia:

$$\hat{\mu}_H(x_i) = x_i \mathbb{1}_{\{|x_i| > \lambda\}},$$

gdzie  $\lambda$  jest dobierana tak, aby zapewniać kontrolę odpowiednich błędów przy założeniu, że dla zdecydowanej większości zmiennych  $\mu = 0$ . Widać, że estymator ten nadaje się do mieszanin rzadkich, do testowania problemów w takich mieszaninach. Poziom  $\lambda$  dobierany jest w zależności o postawionego celu, może być oparty np. o korektę Bonferroniego czy procedurę Benaminiego-Hochberga. Poniżej przedstawimy postać tych odcieć dla testowania hipotez,  $p_i$  to  $p$ -wartość na  $i$ -tej współrzędnej,  $p_{(i)}$  to oczywiście  $i$ -ta uporządkowana  $p$ -wartość:

- Dla kontrolowania FWER używa się korekty Bonferroniego, udowodnione zostało, że dla korekty postaci  $\lambda = q/n$  kontrola FWER wynosi  $q$ ,
- Dla kontrolowania FDR stosuje się procedurę BH( $q$ ), czyli  $\lambda = p(i_0)$ , gdzie  $i_0 = \arg \max_i (p(i) \leq \frac{i}{n} q)$ .

## 2 Zadanie 1

Zadanie pierwsze to zmodyfikowane zadanie drugie z listy piątej. Porównamy estymatory  $MLE$ ,  $MEB$  w trzech różnych przypadkach:

- A.  $\mu = 0$ ,
- B.  $\mu$  pochodzi z rozkładu  $N(0, 5I)$ ,
- C.  $\mu_i \sim N(20, 5)$ .

Zakładamy, że macierz kowariancji nie jest macierzą diagonalną. Wtedy nad estymatorer  $MLE$  powinien przeważać (w sensie błędu średniokwadratowego) estymator  $MEB$ . Głównym problemem przy jego stosowaniu jest wymagana znajomości macierzy kowariancji

Zakładamy, że  $X = (X_1, X_2, \dots, X_p) \sim N(\mu, \Sigma)$ , gdzie  $\Sigma_{i,i} = 1$ , a  $\Sigma_{i,j} = 0.4$  dla  $i \neq j$ .

Wyniki:

	MLE	MEB
A	0.99628	0.99430
B	0.98186	0.98163
C	1.01294	1.01284

Tablica 1: Estymowane błędy średniokwadratowe, niezerowa korelacja

Zaobserwowana różnica pomiędzy estymatorem  $MLE$ , a  $MEB$  jest niewielka, ale pokazuje, że estymator  $MEB$  spisuje się lepiej w powyższym problemie. tak mała różnica może wynikać z niskiej wartości  $\hat{p}$ , równej 2.4925. Po raz kolejny, przytaczając teorię podaną na wykładzie, dopiero jeżeli  $\hat{p} \geq 2$  to estymator  $MEB$  ma mniejszy MSE niż  $MLE$ .

### 3 Zadanie 2

W zadaniu porównamy estymatory  $MLE$  i  $MEB$ , oraz dwie postaci reguły odcięcia w następujących przypadkach:

- A.  $\mu_1 = \dots = \mu_5 = 3.5, \mu_6 = \dots = \mu_{500} = 0$ ,
- B.  $\mu_1 = \dots = \mu_{30} = 2.5, \mu_{31} = \dots = \mu_{500} = 0$ ,
- C.  $\mu_1 = \dots = \mu_{100} = 1.8, \mu_{101} = \dots = \mu_{500} = 0$ ,
- D.  $\mu_1 = \dots = \mu_{500} = 0.4$ ,
- E.  $\mu_i = 3.5 * i^{-1/2}$ ,
- F.  $\mu_i = 3.5 * i^{-1}$ .

Pierwsza dwa estymatory zostały wcześniej opisane, reguła odcięcia natomiast będzie użyta dwukrotnie:

- $\lambda = \lambda_{Bonf}$ , przy czym próg jest ustalony tak, aby kontrolować FWER na poziomie 0.1,
- $\lambda = \lambda_{BH}$ , przy czym próg jest ustalony tak, aby kontrolować FDR na poziomie 0.1

Reguła odcięcia opera się na zasadzie “keep signal, kill noise”.

Otrzymane wyniki:

	MLE	JS	HTbonf	HTbh
A	0.99885	0.11231	0.07009	0.06535
B	1.00330	0.27532	0.34382	0.30843
C	1.00448	0.39758	0.66204	0.65505
D	1.00156	0.14158	0.17035	0.18031
E	1.00085	0.14691	0.16326	0.16514
F	1.00175	0.04290	0.03374	0.03415

Tablica 2: Błędy średniokwadratowe, porównanie estymatorów

Widzimy, że dla każdego z zagadnień błąd średniokwadratowy estymatora największej wiarygodność oscyluje w okolicach wariancji, co jest jasne. Estymator JS zdecydowanie zmniejsza średni błąd kwadratowy, dla każdego z przypadków. Estymatory hard-threshold w problemie A zachowują się lepiej niż dwa pozostałe. Najbardziej uniwersalny wydaje się estymator [JS], gdyż jest zdecydowanie lepszy niż [MLE], a w najgorszych wypadkach jest niewiele gorszy niż estymatory odcinające.